
Operating System MIT 6.828 JOS Lab4 Report

Computer Science
ChenHao(1100012776)

2013 年 10 月 27 日

目录

1	Part A: Multiprocessor Support and Cooperative Multitasking	2
1.1	Exercise 1	2
1.2	Exercise 2	2
1.3	Question 1	3
1.4	Exercise 3	3
1.5	Exercise 4	3
1.6	Exercise 5	4
1.7	Question 2	4
1.8	Exercise 6	4
1.9	Question 3-4	4
1.10	Challenge 2	5
1.11	Question 7	8
1.11.1	sys_exofork	8
1.11.2	sys_env_set_status	8
1.11.3	sys_page_alloc	8
1.11.4	sys_page_map	9
1.11.5	sys_page_unmap	10
2	Part B: Copy-on-Write Fork	10
2.1	Exercise 8	11
2.2	Exercise 9	11
2.3	Exercise 10	12
2.4	Exercise 11	13
2.5	Exercise 12	14
2.5.1	fork	14

2.5.2	duppage	15
2.5.3	pgfault	15
3	Part C: IPC	16
3.1	Exercise 13	16
3.2	Exercise 14	17
3.3	Exercise 15	17
3.4	sys_ipc_recv	17
3.5	sys_try_send	17
3.6	ipc_recv	19
3.7	ipc_send	19

1 Part A: Multiprocessor Support and Cooperative Multitasking

1.1 Exercise 1

这是是要我们实现一个用于简单分配内存空间进行映射的函数，利用以前写的 `boot_map_region` 就可以很容易的实现。

```
void *
mmio_map_region(physaddr_t pa, size_t size)
{
    static uintptr_t base = MMIOBASE;

    pa = ROUNDDOWN(pa, PGSIZE);
    boot_map_region(kern_pgdir, base, ROUNDUP(size, PGSIZE), pa, PTE_PCD |
        PTE_PWT | PTE_W);
    uintptr_t tmp_base = base;
    base += ROUNDUP(size, PGSIZE);
    return (void *) tmp_base;
}
```

1.2 Exercise 2

这一段是在说明 AP 是如何启动的，BSP 在启动 APs 前，会先收集 CPU 信息，APIC IDs, LAPIC 的 MMIO 地址等信息，然后执行 `boot_aps`，在这段中 BSP 依次让每个 AP 启动执行 `mpentry.S` 中的代码（BSP 将代码复制至内存中 `MPENTRY_ADDRESS` 的位置，并将每个的 AP 的 CS:IP 设置好），通过发送 STARTUP IPI 两次来启动 AP（在 `lapic_startup` 函数中说明了，这个启动方式是硬件支持的）之后 AP 就执行启动程序，等执行完后会给 BSP 发送 `CPU_STARTED` 的信号。表示结束，BSP 在 APs 的启动过程中一直处于空循环的状态。

因此 `MPENTRY_ADDRESS` 所在的内存地址是不能够被用于分配其它代码或者数据的，因此在 `page_init` 的需要进行修改。

```
void
page_init(void)
{
    page_free_list = NULL;
    size_t i;
    size_t nf_lb = IOPHYSMEM / PGSIZE;
    size_t nf_ub = PADDR(boot_alloc(0)) / PGSIZE;
    size_t mentry_page = MPENTRY_PADDR / PGSIZE;
    for (i = 0; i < npages; i++) {
        if (i != 0 && (i < nf_lb || i >= nf_ub) && i != mentry_page) {
            pages[i].pp_ref = 0;
            pages[i].pp_link = page_free_list;
            page_free_list = &pages[i];
        } else {
            pages[i].pp_ref = 1;
            pages[i].pp_link = NULL;
        }
    }
}
```

```

    }
}

```

1.3 Question 1

kern/mpentry.S 的链接地址在 KERNBASE 以上，boot apb 之前将其代码拷贝至 MPENTRY_PADDR，而 MPBOOTPHYS 就是用来将高地址的位置进行转化至 MPENTRY_PADDR 开始的低地址的，如果注释掉这个宏，则在使用绝对地址的寻址和跳转则会造成 Page Fault。

1.4 Exercise 3

问题：为什么给 kern_pgdir 即可，不用每个 cpu 的 pgdir 都赋予值？

因为每个 cpu 的 pgdir 在高位都是相同的，即内核部分除了内核栈不同外，代码和数据都是映射到相同的地址下。

```

static void
mem_init_mp(void)
{
    int cpu_id;
    for (cpu_id = 0; cpu_id < NCPU; cpu_id++) {
        boot_map_region(kern_pgdir,
                        KSTACKTOP - cpu_id * (KSTKSIZE + KSTKGAP) - KSTKSIZE,
                        KSTKSIZE,
                        PADDR(percpu_kstacks[cpu_id]),
                        PTE_W);
    }
}

```

1.5 Exercise 4

根据 cpu_id 放置在对应的位置即可。

```

void
trap_init_percpu(void)
{
    // LAB 4: Your code here:
    int cpu_id = thiscpu->cpu_id;
    thiscpu->cpu_ts.ts_esp0 = KSTACKTOP - cpu_id * (KSTKSIZE + KSTKGAP);
    thiscpu->cpu_ts.ts_ss0 = GD_KD;

    gdt[(GD_TSS0 >> 3) + cpu_id] = SEG16(STS_T32A, (uint32_t) (&(thiscpu->cpu_ts
    )),
                                sizeof(struct Taskstate), 0);
    gdt[(GD_TSS0 >> 3) + cpu_id].sd_s = 0;

    ltr(GD_TSS0 + (cpu_id << 3));

    lidt(&idt_pd);
}

```

```
}  

```

1.6 Exercise 5

根据题目要求在对应的地方放上 lock 或者 unlock 即可，连位置都有注释提示，非常简单。

1.7 Question 2

共享内核栈是会存在问题的，在发生中断的时候，对于现场保护的是发生在 big kernel lock 之前的，因此当共享内核栈很可能会产生参数的混乱。

1.8 Exercise 6

这一部分要我们实现 Round-Robin Scheduling，即类似循环链表，每次从刚执行的 env 之后选择最近的一个 RUNNABLE 的进行执行。代码如下：

```
void  
sched_yield(void)  
{  
    struct Env *idle;  
  
    // LAB 4: Your code here.  
    int now_env, i;  
    if (curenv) { // thiscpu->cpu_env  
        now_env = (ENVX(curenv->env_id) + 1) % NENV;  
    } else {  
        now_env = 0;  
    }  
    for (i = 0; i < NENV; i++, now_env = (now_env + 1) % NENV) {  
        if (envs[now_env].env_status == ENV_RUNNABLE) {  
            //cprintf("I am CPU %d , I am in sched yield, I find ENV %d\n",  
                thiscpu->cpu_id, now_env);  
            env_run(&envs[now_env]);  
        }  
    }  
    if (curenv && curenv->env_status == ENV_RUNNING) {  
        env_run(curenv);  
    }  
    // sched_halt never returns  
    sched_halt();  
}
```

1.9 Question 3-4

Question 3: 由于 Env 在 mem_init 中分配了内存进行存储并建立了映射，而这个映射在每个 CPU 上都是一致的，因此 lcr3() 后对于 Env 的还是存在虚拟内存到物理内存的映射的。

Question 4: 保存现场是为了之后 CPU 进行继续处理这个 environment 的时候保证不会造成错误。保护现场发生在发生中断的情况下，这时候堆栈上储存了当前 environment 的信息，之后再通过 `curenv->env_tf = *tf` 来保存在 environment 中。

1.10 Challenge 2

设置一个带有优先级的调度，我实现了一个非常弱智的，每次找到可运行的优先级最高的，如果优先级相同，则优先处理刚处理完的进程号之后最近的一个进程。对于优先级的表示，我在 struct Env 中设置了一位 `env_priority` 表示优先级，越大表示优先级越高。

因此调度就变为了：

```
void
sched_yield(void)
{
    struct Env *idle;

    int now_env, i;
    if (curenv) {                // thiscpu->cpu_env
        now_env = (ENVX(curenv->env_id) + 1) % NENV;
    } else {
        now_env = 0;
    }
    uint32_t max_priority = 0;
    int select_env = -1;
    for (i = 0; i < NENV; i++, now_env = (now_env + 1) % NENV) {
        if (envs[now_env].env_status == ENV_RUNNABLE && (envs[now_env].
            env_priority > max_priority || select_env == -1)) {
            //cprintf("I am CPU %d , I am in sched yield, I find ENV %d\n",
                thiscpu->cpu_id, now_env);
            select_env = now_env;
            max_priority = envs[now_env].env_priority;
        }
    }
    if (select_env >= 0 && (!curenv || curenv->env_status != ENV_RUNNING ||
        max_priority >= curenv->env_priority)) {
        env_run(&envs[select_env]);
    }

    if (curenv && curenv->env_status == ENV_RUNNING) {
        env_run(curenv);
    }

    // sched_halt never returns
    sched_halt();
}
```

为了测试，我首先增加了一个更改 priority 的系统调用：

```
static int
sys_set_priority(envid_t envid, uint32_t new_priority)
{
    struct Env *env;
```

```

    int r = env_id2env(env_id, &env, 1);
    if (r < 0) return -E_BAD_ENV;

    env->env_priority = new_priority;
    return 0;
}

```

我在用户 `fork()` 库函数增加了一个 `static` 变量 `num`，使得其递减，并设置刚创建的子进程的 `priority` 为 `num`：

```

env_id_t
fork(void)
{
    static int num = 0x100;

    // LAB 4: Your code here.
    set_pgfault_handler(pgfault);
    int childpid = sys_exofork();
    if (childpid < 0) {
        panic("fork sys_exofork error : %e\n", childpid);
    }
    int r;

    if (childpid == 0) {
        .....
    } else {
        .....

        // LAB 4 Challenge , set childenv's priority
        num--;
        if (num == 0) num = 0x100;
        r = sys_set_priority(childpid, num);
        if (r < 0) panic("fork, set priority error\n");

        // mark the child as runnable and return
        r = sys_env_set_status(childpid, ENV_RUNNABLE);
        if (r < 0) panic("fork, set child process to ENV_RUNNABLE error : %e\n",
            r);
        return childpid;
    }
}

```

这样就可以进行测试了，我把 `hello.c` 更改为了下面的代码，根据我们之前的铺垫，预期就是执行完子进程 0，才会执行子进程 1，才会执行子进程 2，才会执行子进程 3。

```

#include <inc/lib.h>

void
umain(int argc, char **argv)
{
    cprintf("hello, world\n");
    cprintf("i am environment %08x\n", thisenv->env_id);

    int i, child, j;
    for (i = 0; i != 3; i++) {

```

```

    child = fork();
    if (child == 0) {
        for (j = 0; j != 10; j++) {
            cprintf("hello world from : %d\n", i);
            sys_yield();
        }
        break;
    }
}
}

```

```

[00000000] new env 00001000
hello, world
i am environment 00001000
[00001000] new env 00001001
[00001000] new env 00001002
hello world from : 0
hello world from : 0
hello world from : 0
hello world from : 0
hello world from : 0
hello world from : 0
hello world from : 0
hello world from : 0
hello world from : 0
hello world from : 0
[00001001] exiting gracefully
[00001001] free env 00001001
[00001000] new env 00002001
hello world from : 1
hello world from : 1
hello world from : 1
hello world from : 1
hello world from : 1
hello world from : 1
hello world from : 1
hello world from : 1
hello world from : 1
hello world from : 1
[00001002] exiting gracefully
[00001002] free env 00001002
[00001000] exiting gracefully
[00001000] free env 00001000
hello world from : 2
hello world from : 2
hello world from : 2
hello world from : 2
hello world from : 2
hello world from : 2
hello world from : 2
hello world from : 2
hello world from : 2
hello world from : 2
[00002001] exiting gracefully
[00002001] free env 00002001

```

和预期一致!

1.11 Question 7

1.11.1 sys_exofork

这个部分是生成一个新的 environment，使得其寄存器的值与当前的 environment 的一样，对于新的 environment 返回值为 0 (%eax=0)。对于该函数返回新的 environment 的 pid 号。

```
static env_t
sys_exofork(void)
{
    struct Env * new_env;
    int r = env_alloc(&new_env, curenv->env_id);
    if (r < 0) return r;

    new_env->env_status = ENV_NOT_RUNNABLE;
    memcpy((void *)(&new_env->env_tf), (void *)(&curenv->env_tf), sizeof(struct
        Trapframe));

    // for children environment, return 0
    new_env->env_tf.tf_regs.reg_eax = 0;

    return new_env->env_id;
}
```

1.11.2 sys_env_set_status

这个是设置 environment 的 status，按照注释做即可。

```
static int
sys_env_set_status(env_t env_id, int status)
{
    if (status != ENV_RUNNABLE && status != ENV_NOT_RUNNABLE)
        return -E_INVALID;

    struct Env * env;
    int r = env2env(env_id, &env, 1);
    if (r < 0) return r;
    env->env_status = status;
    return 0;
}
```

1.11.3 sys_page_alloc

这个函数是为 environment 创建虚拟地址 va 的映射页，按照注释一条一条做即可。注意如何无法建立映射，则新分配的页需要释放掉。

```
static int
sys_page_alloc(env_t env_id, void *va, int perm)
{
    struct Env * env;
    int r = env2env(env_id, &env, 1);
```

```

    if (r < 0) return -E_BAD_ENV;

    if ((uint32_t)va >= UTOP || ROUNDUP(va, PGSIZE) != va) return -E_INVAL;

    if (!((perm & PTE_U) && (perm & PTE_P) && (perm & (~PTE_SYSCALL))==0))
        return -E_INVAL;

    struct PageInfo * pg = page_alloc(ALLOC_ZERO);
    if (pg == NULL) return -E_NO_MEM;
    if (page_insert(env->env_pgdir, pg, va, perm) < 0) {
        // page_insert fails, should free the page you allocated!
        page_free(pg);
        return -E_NO_MEM;
    }
    return 0;
}

```

1.11.4 sys_page_map

按照给定的进程，和虚拟地址，拷贝其映射至另一个进程的给定的虚拟地址上，按照注释一条一条做即可。

```

static int
sys_page_map(envid_t srcenvid, void *srcva,
             envid_t dstenvid, void *dstva, int perm)
{
    struct Env * dstenv, * srcenv;
    int r = envid2env(dstenvid, &dstenv, 1);
    if (r < 0) return -E_BAD_ENV;
    r = envid2env(srcenvid, &srcenv, 1);
    if (r < 0) return -E_BAD_ENV;

    if ((uint32_t)srcva >= UTOP || ROUNDUP(srcva, PGSIZE) != srcva) return -
        E_INVAL;
    if ((uint32_t)dstva >= UTOP || ROUNDUP(dstva, PGSIZE) != dstva) return -
        E_INVAL;

    // struct PageInfo * page_lookup(pde_t *pgdir, void *va, pte_t **pte_store)
    struct PageInfo * pg;
    pte_t * pte;
    pg = page_lookup(srcenv->env_pgdir, srcva, &pte);
    if (pg == NULL) return -E_INVAL;

    if (!((perm & PTE_U) && (perm & PTE_P) && (perm & (~PTE_SYSCALL))==0))
        return -E_INVAL;

    if ((perm & PTE_W) && ((*pte) & PTE_W) == 0) return -E_INVAL;

    // int page_insert(pde_t *pgdir, struct PageInfo *pp, void *va, int perm)
    if (page_insert(dstenv->env_pgdir, pg, dstva, perm) < 0) return -E_NO_MEM;

    return 0;
}

```

1.11.5 sys_page_unmap

按照注释一条一条做即可。

```
static int
sys_page_unmap(envid_t envid, void *va)
{
    struct Env * env;
    int r = envid2env(envid, &env, 1);
    if (r < 0) return -E_BAD_ENV;

    if ((uint32_t)va >= UTOP || ROUNDUP(va, PGSIZE) != va) return -E_INVAL;

    // void page_remove(pde_t *pgdir, void *va)
    page_remove(env->env_pgdir, va);

    return 0;
}
```

注意到目前写的调度都是执行完一个 environment 之后就结束，剩余最后一个作为 monitor，其余的 CPU 均 HLT 住，但是注意不能把所有 CPU 都 HLT，这样会出现中断 13。当我尝试在 init.c 中设置 environment 的数量大于 CPU 核的数量时，就会造成中断 13，因为所有的 CPU 都 HLT 了。我在这里调试了很久，花了很长时间，最后才发现竟然是没考虑清楚。

2 Part B: Copy-on-Write Fork

fork() 指令会根据当前进程生成一个新的与原进程一样的 (除了 pid 号不一样) 的进程，他们拥有独立的内存空间，独立的寄存器，独立的用户栈等等。因此我们对于 fork() 的执行需要将内存中完全复制一份，这个代价是非常高的。我们可以采用 Copy-on-Write 的技术，使用 Copy-on-Write 的原因在于，fork() 中有的内存是多个进程是只读的，那么我们完全可以将这部分的内存不进行复制；其次并不是所有的数据都需要更改，所以我们可以共同使用同一个物理内存，当进行写操作的时候，再分为独立的内存。其次还有一个原因是许多情况下 fork() 之后会执行 exec()，因此 fork() 采用 Copy-on-Write 是一个比较很好的减少不必要操作，节省内存的一个方法。

如何得知某一块内存是被多个进程共用，如何得知这样的内存存在被写的时候需要进行复制。对于前一个问题，PTE 表项中有由一个专门的标志为 PTE_COW，表示这个页是否使用了 Copy-on-Write。如何在写的时候进行复制，这里采用触发 Page Fault 的方法。JOS 在内核中注册了一个 Page fault 的处理程序，允许用户进程将自己的页错误函数注册到进程结构中。这样当发生页错误的时候可以在 user-level 下实现对 page level 的处理，增大了灵活性，而且一定程度上节省了 page fault 霸占内核的时间。

为了实现 user-level 的 page fault，那么就不能使用内核栈用于保存信息，因此就出现了 Exception Stack，是 user-level page fault handler 运行时用的栈，用于保存信息。

2.1 Exercise 8

如果用户需要使用自己的 Page Fault Handler, 则事先需要向内核注册 handler 所在的位置, 保存在用户进程的 `env_pagfault_upcall` 变量中, 此处就是注册 user-level page fault handler。

```
static int
sys_env_set_pgfault_upcall(envid_t envid, void *func)
{
    struct Env * env;
    int r = envid2env(envid, &env, 1);
    if (r < 0) return r;

    env->env_pgfault_upcall = func;
    return 0;
}
```

当产生 Page Fault 的时候, 如果是内核模式下产生的, 则产生 panic, 一定是系统出现了 bug。如果是用户模式下产生的 page fault 且存在 user-level page fault 的 handler 的时候, 则需要保存现场信息至 user exception stack。并设置好当前 env 的 eip 为 user-level page fault handler 的入口地址, 并将栈指向当前 user exception stack 的位置。然后返回用户态执行 user-level page fault handler。特别要注意在 user-level page fault handler 中, 是在用户模式下执行的, 并且所使用的栈是在 user exception stack 上。当 user-level page fault handler 执行完成后, 会切换会用户进程和用户运行栈下继续执行。

2.2 Exercise 9

此处就为 kernel 在接受到 page_fault 异常的时候, 进行的处理。如果是在用户模式且存在注册的 page fault handler, 则需要存栈。如果是 page fault 嵌套, 则需要在异常栈开始的地方多压一个空的 32-bit word。为什么要这样做, 后面的 exercise 会进行解释。

```
void
page_fault_handler(struct Trapframe *tf)
{
    uint32_t fault_va;

    // Read processor's CR2 register to find the faulting address
    fault_va = rcr2();

    // Handle kernel-mode page faults.

    // LAB 3: Your code here.
    if (tf->tf_cs == GD_KT)
        panic("page_fault_handler : page fault in kernel\n");

    if (curenv->env_pgfault_upcall != NULL) {
        // exist env's page fault upcall

        struct UTrapframe * ut;
        if (tf->tf_esp >= UXSTACKTOP - PGSIZE && tf->tf_esp <= UXSTACKTOP - 1) {
```

```

        // already in user exception stack, should first push an empty
        // 32-bit word
        ut = (struct UTrapframe *)((void *)tf->tf_esp - sizeof(struct
            UTrapframe) - 4);
        user_mem_assert(curenv, (void *)ut, sizeof(struct UTrapframe) + 4,
            PTE_U | PTE_W);
    } else {
        // it's the first time in user exception stack
        ut = (struct UTrapframe *)(UXSTACKTOP - sizeof(struct UTrapframe
            ));
        user_mem_assert(curenv, (void *)ut, sizeof(struct UTrapframe),
            PTE_U | PTE_W);
    }

    ut->utf_esp = tf->tf_esp;
    ut->utf_eflags = tf->tf_eflags;
    ut->utf_eip = tf->tf_eip;
    ut->utf_regs = tf->tf_regs;
    ut->utf_err = tf->tf_err;
    ut->utf_fault_va = fault_va;

    curenv->env_tf.tf_eip = (uint32_t)curenv->env_pgfault_upcall;
    curenv->env_tf.tf_esp = (uint32_t)ut;
    env_run(curenv);
}

// Destroy the environment that caused the fault.
cprintf("[%08x] user fault va %08x ip %08x\n",
    curenv->env_id, fault_va, tf->tf_eip);
print_trapframe(tf);
env_destroy(curenv);
}

```

2.3 Exercise 10

`_pgfault_upcall` 实际上实现到真正 handler 的跳转，待 handler 处理完后进行环境的恢复。对于栈的恢复是比较简单的，因为 `old-esp` 和 `old-eip` 已经存在了栈中，而对于 `eip` 的恢复就需要使用 `ret` 的机制，即弹出栈顶元素作为 `eip`，跳转到 `eip` 的位置。因此我们在 `ret` 之前只需要把 `eip` 存放在栈顶的位置即可，应该放在哪里？还记得如果产生了 `page fault` 的嵌套，则在栈中会多存放一个空的 4 字节，这就是用于返回 `eip` 的存放。对于第一层的 `page fault`，则可以把 `eip` 放在原来的用户运行栈的下一个 4 字节位置，并将 `%esp` 指向 `eip` 的位置，使用 `ret` 就可以实现跳转了。

对于 4 字节是否是必须的？为什么不能在最后再将返回的 `%eip` 弹入栈中？这是因为你是无法不污染寄存器的情况下实现这样的操作的，即为了在最后将 `%eip` 弹入栈中，你必须需要寄存器来存储。而这样对于保存其值的寄存器便无法不被污染。

```

// fix old esp
movl 0x30(%esp), %eax
subl $0x4, %eax
movl %eax, 0x30(%esp)

```

```

// set trap-time %eip
movl 0x28(%esp), %ebx
movl %ebx, (%eax)

// Restore the trap-time registers. After you do this, you
// can no longer modify any general-purpose registers.
addl $0x08, %esp // ignore err_code and fault_va
popal // restore registers

// Restore eflags from the stack. After you do this, you can
// no longer use arithmetic operations or anything else that
// modifies eflags.
addl $0x04, %esp // ignore eip
popfl // modify eflags

// Switch back to the adjusted trap-time stack.
popl %esp

// Return to re-execute the instruction that faulted.
ret

```

2.4 Exercise 11

这里实际上是提供给用户的库函数，需要做的有申请分配 exception stack 的空间，以及系统调用设置 user-level page fault 函数。注意给系统的实际上是 `_pgfault_upcall`，这是 user-level page fault 的入口程序，在实际的 handler 存放在 `_pgfault_handler` 中，这样从内核态到用户态 page fault 的转换，实际上是到了 `_pgfault_upcall`，再在其中实现到真正 handler: `_pgfault_handler` 的跳转。

```

void
set_pgfault_handler(void (*handler)(struct UTrapframe *utf))
{
    int r;
    if (_pgfault_handler == 0) {
        // First time through!
        // LAB 4: Your code here.
        //int sys_page_alloc(envid_t envid, void *va, int perm)
        r = sys_page_alloc(0, (void*)(UXSTACKTOP - PGSIZE), PTE_U | PTE_W |
            PTE_P);
        if (r < 0) {
            panic("sys_page_alloc error : %e\n", r);
        }
        // how to know envid, put 0, envid2env will help us to get curenv in
        // syscall
        r = sys_env_set_pgfault_upcall(0, _pgfault_upcall);
        if (r < 0) {
            panic("sys_env_set_pgfault_upcall error : %e\n", r);
        }
    }
    // Save handler pointer for assembly to call.
    _pgfault_handler = handler;
}

```

```
}  

```

2.5 Exercise 12

这个部分就是要真正实现一个带 Copy-on-Write 的提供给用户的 fork 函数了。为了实现 Copy-on-Write 需要先注册一个 pgfault_handler，这样当某一个进程对某一块共享区域进行写入的时候，就绪要进行内存的复制使得这块内存不共享。然后进行 sys_exofork()，由于此时子进程还处于 NOT_RUNNABLE 的状态，父进程需要对子进程构建内存的映射（这里只需要复制 0 ~ UTOP 中存在的并且是用户的内存条目，对于内核态的数据和代码都是共享的，已经存在于子进程的页表中，无需拷贝），以及创建分配一块 exception stack 的内存，并设置子进程的 pgfault_handler。当这些都完成了，说明子进程已经可以开始运行了，就可以标记子进程的状态为 RUNNABLE 了。

特别注意当子进程进行执行的时候，需要更新子进程的 thisenv 号。

2.5.1 fork

```
envid_t  
fork(void)  
{  
    set_pgfault_handler(pgfault);  
    int childpid = sys_exofork();  
    if (childpid < 0) {  
        panic("fork sys_exofork error : %e\n", childpid);  
    }  
    int r;  
  
    if (childpid == 0) {  
        // child process  
        // Remember to fix "thisenv" in the child process. ???  
        thisenv = &envs[ENVX(sys_getenvid())];  
        // cprintf("fork child ok\n");  
        return 0;  
    } else {  
        // map page to new environment  
        // kernel page is already in new environment  
        uint32_t i;  
        for (i = 0; i != UTOP; i += PGSIZE)  
            if ((uvpd[PDX(i)] & PTE_P) && (uvpt[i / PGSIZE] & PTE_P) && (uvpt[i / PGSIZE] & PTE_U)) {  
                duppage(childpid, i / PGSIZE);  
            }  
  
        // allocate exception stack  
        r = sys_page_alloc(childpid, (void *) (UXSTACKTOP - PGSIZE), PTE_U | PTE_W | PTE_P);  
        if (r < 0) panic("fork, sys_page_alloc user exception stack error : %e\n", r);  
  
        // set user environment user page fault handler
```

```

extern void _pgfault_upcall(void);
r = sys_env_set_pgfault_upcall(childpid, _pgfault_upcall);
if (r < 0) panic("fork, set pgfault upcall fail : %e\n", r);

// mark the child as runnable and return
r = sys_env_set_status(childpid, ENV_RUNNABLE);
if (r < 0) panic("fork, set child process to ENV_RUNNABLE error : %e\n",
    r);

// cprintf("fork father ok!");
return childpid;
}

panic("fork not implemented");
}

```

2.5.2 duppage

这部分就是实现页表的复制，需要区分读和写即可。如果是读，则需要更改子进程的同时自己页表的标志位也需要更改。

```

static int
duppage(env_t env, unsigned pn)
{
    // do not dup exception stack
    if (pn * PGSIZE == UXSTACKTOP - PGSIZE) return 0;

    int r;
    void * addr = (void *) (pn * PGSIZE);
    if ((uvpt[pn] & PTE_W) || (uvpt[pn] & PTE_COW)) {
        // cow
        r = sys_page_map(0, addr, env, addr, PTE_COW | PTE_P | PTE_U);
        if (r < 0) panic("duppage sys_page_map error : %e\n", r);

        r = sys_page_map(0, addr, 0, addr, PTE_COW | PTE_P | PTE_U);
        if (r < 0) panic("duppage sys_page_map error : %e\n", r);
    } else {
        // read only
        r = sys_page_map(0, addr, env, addr, PTE_P | PTE_U);
        if (r < 0) panic("duppage sys_page_map error : %e\n", r);
    }

    return 0;
}

```

2.5.3 pgfault

这部分就是真正处理 Copy-On-Write 的地方，就是将共享的内存进行复制即可。这里我出现了一个低级错误，对于 `utf->utf_fault_va` 我想当然地以为是对齐 PGSIZE，实际上并不是，这里花了我挺长时间进行调试的。

```

static void
pgfault(struct UTrapframe *utf)
{
    void *addr = (void *) utf->utf_fault_va;
    uint32_t err = utf->utf_err;
    int r;

    if ((err & FEC_WR) == 0)
        panic("pgfault, the fault is not a write\n");

    uint32_t uaddr = (uint32_t) addr;
    if ((uvpd[PDX(addr)] & PTE_P) == 0 || (uvpt[uaddr / PGSIZE] & PTE_COW) == 0)
    {
        panic("pgfault, not a copy-on-write page\n");
    }

    // static int sys_page_alloc(envir_t env, void *va, int perm)
    r = sys_page_alloc(0, (void *)PFTEMP, PTE_W | PTE_U | PTE_P);
    if (r < 0) panic("pgfault, sys_page_alloc error : %e\n", r);

    // Oh my god, I forget this at the first, it waste me a lot of time to debug
    !!!
    addr = ROUNDDOWN(addr, PGSIZE);

    memcpy(PFTEMP, addr, PGSIZE);

    r = sys_page_map(0, PFTEMP, 0, addr, PTE_W | PTE_U | PTE_P);
    if (r < 0) panic("pgfault, sys_page_map error : %e\n", r);

    return;
}

```

运行 lib/fork.c, 效果和给定的一致。这样 PartB 就结束了。

3 Part C: IPC

3.1 Exercise 13

这部分是设置外部中断，注意要修改 eflags 寄存器的 FL_IF 位，来接受外部中断。这部分和 Lab3 几乎一样。

```

// in trapentry.S add :
TRAPHANDLER_NOEC(vec32, IRQ_OFFSET + IRQ_TIMER)
TRAPHANDLER_NOEC(vec33, IRQ_OFFSET + IRQ_KBD)
TRAPHANDLER_NOEC(vec36, IRQ_OFFSET + IRQ_SERIAL)
TRAPHANDLER_NOEC(vec39, IRQ_OFFSET + IRQ_SPURIOUS)
TRAPHANDLER_NOEC(vec46, IRQ_OFFSET + IRQ_IDE)
TRAPHANDLER_NOEC(vec51, IRQ_OFFSET + IRQ_ERROR)

// in trap_init add :
SETGATE(idt[IRQ_OFFSET + IRQ_TIMER], 0, GD_KT, vec32, 0);
SETGATE(idt[IRQ_OFFSET + IRQ_KBD], 0, GD_KT, vec33, 0);
SETGATE(idt[IRQ_OFFSET + IRQ_SERIAL], 0, GD_KT, vec36, 0);

```

```

SETGATE(idt[IRQ_OFFSET + IRQ_SPURIOUS], 0, GD_KT, vec39, 0);
SETGATE(idt[IRQ_OFFSET + IRQ_IDE], 0, GD_KT, vec46, 0);
SETGATE(idt[IRQ_OFFSET + IRQ_ERROR], 0, GD_KT, vec51, 0);

// in env_alloc add :
e->env_tf.tf_eflags |= FL_IF;

```

3.2 Exercise 14

这部分是处理时钟中断，实现 Time-Sharing。lab 已经帮我实现好细节了，我们只需要在 trap.c 中遇到时钟中断调用相应函数即可：

```

if (tf->tf_trapno == IRQ_OFFSET + IRQ_TIMER) {
    lapic_eoi();
    sched_yield();
    return;
}

```

3.3 Exercise 15

这部分我们提供两个系统调用来实现进程间的通信，程序注释说的非常详细，一步一步做即可。

3.4 sys_ipc_recv

```

static int
sys_ipc_recv(void *dstva)
{
    // cprintf("I am receiving???\n");
    // LAB 4: Your code here.
    if (((uint32_t)dstva < UTOP) && ROUNDUP(dstva, PGSIZE) != dstva) return -
        E_INVAL;
    curenv->env_ipc_recving = true;           // Env is blocked receiving
    curenv->env_ipc_dstva = dstva;            // VA at which to map received page
    curenv->env_ipc_from = 0;                 // set from to 0
    curenv->env_status = ENV_NOT_RUNNABLE;    // mark it not runnable
    // cprintf("I am receiving!!!\n");
    // cprintf("%d, %d\n", curenv->env_ipc_recving, curenv->env_ipc_from);
    sched_yield();                           // give up the CPU

    return 0;
}

```

3.5 sys_try_send

中间我很不小心填错发消息的 envid，导致陷入了无尽的调试之中，花了将近 2 个小时才找到错误，太伤心了。

```

static int
sys_ipc_try_send(envid_t envid, uint32_t value, void *srcva, unsigned perm)
{
    struct Env * env;
    int r = envid2env(envid, &env, 0);
    // -E_BAD_ENV if environment envid doesn't currently exist.
    if (r < 0) return -E_BAD_ENV;

    // -E_IPC_NOT_RECV if envid is not currently blocked in sys_ipc_recv,
    // or another environment managed to send first.
    if (env->env_ipc_recving == false || env->env_ipc_from != 0) {
        return -E_IPC_NOT_RECV;
    }

    // -E_INVALID if srcva < UTOP but srcva is not page-aligned.
    if ((uint32_t)srcva < UTOP && ROUNDUP(srcva, PGSIZE) != srcva)
        return -E_INVALID;

    // -E_INVALID if srcva < UTOP and perm is inappropriate
    if ((uint32_t)srcva < UTOP && (!((perm & PTE_U) && (perm & PTE_P) && (perm &
        (~PTE_SYSCALL)) == 0)))
        return -E_INVALID;

    // -E_INVALID if srcva < UTOP but srcva is not mapped in the caller's address
    // space
    pte_t * pte;
    struct PageInfo * pg = page_lookup(curenv->env_pgdir, srcva, &pte);
    if ((uint32_t)srcva < UTOP && pg == NULL)
        return -E_INVALID;

    // -E_INVALID if (perm & PTE_W), but srcva is read-only in the
    // current environment's address space.
    if ((perm & PTE_W) && (*pte & PTE_W) == 0)
        return -E_INVALID;

    // -E_NO_MEM if there's not enough memory to map srcva in envid's
    // address space.
    if ((uint32_t)srcva < UTOP) {
        r = page_insert(env->env_pgdir, pg, ROUNDDOWN(srcva, PGSIZE), perm);
        if (r < 0) return -E_NO_MEM;
        env->env_ipc_perm = perm;
    } else env->env_ipc_perm = 0;

    env->env_ipc_recving = false;

    // ... I mistake write env->env_ipc_from = envid in the first
    // ... Debug a lot of time...
    env->env_ipc_from = curenv->env_id;
    env->env_ipc_value = value;
    env->env_tf.tf_regs.reg_eax = 0;
    env->env_status = ENV_RUNNABLE;

    return 0;
}

```

3.6 ipc_recv

```
int32_t
ipc_recv(envid_t *from_env_store, void *pg, int *perm_store)
{
    // LAB 4: Your code here.
    int r;
    if (pg != NULL) {
        r = sys_ipc_recv(pg);
    } else {
        r = sys_ipc_recv((void *)UTOP);
    }

    if (r == 0) {
        if (from_env_store != NULL) *from_env_store = thisenv->env_ipc_from;
        if (perm_store != NULL) *perm_store = thisenv->env_ipc_perm;
        // cprintf("Receive %d\n", thisenv->env_ipc_value);
        return thisenv->env_ipc_value;
    } else {
        // fails;
        if (from_env_store != NULL) *from_env_store = 0;
        if (perm_store != NULL) *perm_store = 0;
        return r;
    }
}
```

3.7 ipc_send

```
void
ipc_send(envid_t to_env, uint32_t val, void *pg, int perm)
{
    int r;
    if (pg == NULL) pg = (void *)UTOP;

    while ((r = sys_ipc_try_send(to_env, val, pg, perm)) != 0) {
        if (r == -E_IPC_NOT_RECV) {
            // cprintf("Try Again and Again...\n");
            sys_yield();
        } else {
            panic("ipc_send error %e\n", r);
        }
    }
    return;
}
```